

Один ограниченный эксперимент с обучением

M21 • 01.08.2028 - 03.09.2028 • 75 часов

Что получится к концу месяца

Итог — learning_eval_v1: сравнение обучения по демонстрациям и небольшого эксперимента с PPO с неизменным классическим управлением. В отчёт войдут испытания в условиях, отсутствовавших при обучении, и проверка возврата к базовому алгоритму. Основная задача — небольшая коррекция ориентации корпуса стоящего четвероногого робота в заданном диапазоне наклонов и возмущений. Обучаемая часть выдаёт только ограниченную поправку верхнего уровня; приводной контур, контактные ограничения и независимый наблюдатель остаются классическими.

За 75 часов ты изучишь сбор демонстраций, клонирование поведения, MDP, награду, PPO, выбор начальных значений генератора случайных чисел (seed), рандомизацию параметров среды и защитный фильтр. Полноценная динамическая походка с нуля, прыжки и перенос на реальные приводы выходят за рамки модуля. Все опыты с обучением по демонстрациям (IL) и с подкреплением (RL) здесь выполняются в симуляции. Рост награды сам по себе не даёт оснований запускать новую политику на оборудовании.

Входные условия

Из M19–M20 нужны устойчивая стойка (stand) или режим паузы медленной походки (pause), проверенный QP либо консервативный силовой режим, реальные ограничения модели и независимое выявление устаревшего состояния, потери опоры и недопустимой команды. Из M18 — правила работы с данными, разделение выборок по группам, небольшая сеть, журнал эксперимента и профиль нагрузки на CPU. Сохрани рабочую версию базового алгоритма с идентификатором коммита и конфигурацией; при сравнении с ML она должна оставаться неизменной.

Если классическое удержание не проходит собственные проверки, сначала разберись с этим дефектом. Проверь данные, опиши MDP и выполни обучение по имеющимся корректным демонстрациям; опыты с обученной политикой в замкнутом контуре отложи до устранения причины. До завершения проверок обучение остаётся необязательной веткой, а применение на оборудовании не допускается. G3, перенесённый в общий календарь, остаётся отдельной интеграционной проверкой и не заменяет допуска к эксперименту.

Как связать с твоими проектами

Для шагающего робота результат покажет, может ли малая обучаемая поправка улучшить восстановление корпуса при ограниченной неопределённости. Для руки аналог — ограниченная поправка положения, ориентации или силы захвата к команде рабочего классического регулятора. В этом месяце не обучай обе системы сразу: запиши перенос постановки на палец как отдельное упражнение, указав признаки контакта и другой смысл отказа.

Успешным результатом может оказаться вывод «базовый алгоритм достаточно хорош, ML не улучшает выбранные показатели». Такой вывод принимается, если условия сравнения одинаковы, а результаты воспроизводимы. Новая политика не обязана заменять проверенный алгоритм; её полезность должна подтверждаться измерениями, а ограничения — оставаться видимыми.

Время, вычисления и границы эксперимента

План на 75 часов

Часы 1–20: 10 часов теории и 10 практики. Изучи набор демонстраций, клонирование поведения, накопление ошибок, сдвиг распределения посещаемых состояний, идею DAgger и аудит данных. Подготовь небольшой набор демонстраций, разделённый по эпизодам, и первую модель подражания. Оцени её по записи и в замкнутом контуре. Базовый алгоритм управления уже должен работать: его повторная разработка в эти часы не входит.

Часы 21–40: 10 часов теории и 10 практики. Изучи MDP, наблюдения, действия, награду, завершение эпизодов, алгоритм PPO, кривые обучения и разброс результатов при разных значениях seed. Подготовь корректную среду и выполни три небольших воспроизводимых запуска. Для SAC достаточно понять отличия от PPO; реализовывать второй алгоритм RL не требуется.

Часы 41–60: 10 часов теории и 10 практики. Разбери влияние массы, трения, задержки, шума и рельефа, постепенное усложнение обучения и границы рандомизации. Подготовь отдельные профили обучения и оценки, проверь каждое семейство параметров и выполни ограниченные абляции. Часы 61–75: 5 часов теории и 10 практики. Изучи OOD, защитный фильтр, независимые ограничения, резервный режим и восстановление после толчка. Составь итоговую таблицу проверок и протокол будущего переноса из симуляции на оборудование.

Реалистичный бюджет CPU

Платформа по умолчанию — CPU и существующий симулятор без графики. Начни с сети в один-два небольших слоя и двух действий: поправок крена и тангажа. Для каждого из трёх основных запусков PPO с разными значениями seed задай верхнюю границу 50 000 шагов политики либо 30 минут обучения, что наступит раньше; это учебный лимит, не обещание сходимости. Запиши фактические шаги и время. При слишком медленной среде уменьши число шагов одинаково для всех значений seed, сохрани три запуска и укажи, как лимит ограничивает выводы.

Для пяти коротких абляций используй один заранее выбранный seed и максимум 10 минут на вариант. Такой анализ предварительный: он не заменяет сравнение трёх запусков с разными значениями seed для основного результата. Общее машинное время этих тренировок ограничено; пока идут запуски, анализируй предыдущие логи в том же практическом блоке, не учитывая одно время дважды. GPU не предполагается. Apple M4 — не CUDA-платформа; Isaac Lab рассматривается отдельно только при совместимом оборудовании.

Размещение в календаре

Теория: пять занятий по 2 часа в каждом из первых трёх блоков, затем 2 + 2 + 1. Практика: четыре блока по 10 часов с перерывами отдельно. Границы дат могут совпадать с соседним модулем; отдых, отпуска и интеграционные блоки сохраняются по общему плану. Номера часов задают порядок работы; они не создают нового календаря и не предполагают повторного учёта времени.

Демонстрации: чему именно учить модель

Две роли обучаемого компонента

При клонировании поведения (behavior cloning, BC) экспертом служит неизменная классическая функция: по наблюдению она выбирает ограниченную целевую поправку ориентации корпуса. Подбери сценарии с небольшими ненулевыми наклонами и возмущениями, чтобы действия не были почти всегда нулевыми. Регулятор нижнего уровня из M20 отрабатывает эту цель. Для PPO далее используется отдельный режим корректирующей добавки (residual): к классической команде прибавляется ещё меньшая обучаемая поправка. Обозначай режимы отдельно и не объединяй их в одной метрике.

Задача 1. Аудит эксперта и данных

Собери независимые эпизоды стояния с малыми отклонениями и заранее известными воздействиями. Записывай observation, expert_action, applied_action, контакты, возраст данных, идентификатор сценария, значение seed и причину завершения. Истинные параметры симулятора и эталонное состояние сохраняй для анализа, но не подавай политике, если будущий робот их не измеряет. Перечисли все входы эксперта: скрытая привилегированная информация должна быть явно отмечена.

Раздели целые эпизоды на обучающую (train), валидационную (validation) и итоговую тестовую (final test) выборки. Все окна одного опыта должны попасть в одну выборку; параметры нормализации рассчитывай только по обучающей. Проверь распределение действий и состояний, долю насыщений, ошибочные команды и эпизоды с отказами. Неправильные демонстрации не удаляй молча: укажи правило исключения до обучения и сохрани число исключений. Не включай в обучение отсчёты после физически некорректного сброса среды (reset).

Задача 2. Клонирование поведения

Обучи компактную сеть минимизировать средний квадрат отклонения от экспертной поправки в нормированных единицах. Для углов дополнительно укажи MAE в радианах или градусах с явным обозначением. Начни с простейшего метода «среднее действие на обучающей выборке» и линейной модели; нейросеть сравнивается с ними на одинаковом наборе. Отдельно проверь большие экспертные коррекции: средняя ошибка может скрыть плохое поведение именно в трудный момент.

Сохрани веса, параметры нормализации, список признаков, конфигурацию и предсказания. Для проверки воспроизведи отдельный эпизод и построй график действий эксперта и модели. Граничные случаи: нулевая команда, неизвестная схема, устаревшее наблюдение и действие на пределе. В контроллер передаётся только действие, прошедшее независимую проверку; подмену NaN допустимым нулём нельзя оставлять без записи в журнале.

Основная цель первого шага — не доказать превосходство над экспертом, а научиться воспроизводить ограниченное решение по доступным наблюдениям. Если эксперт использует информацию, которую модель не видит, часть ошибки может быть принципиальной; это нужно обнаружить до увеличения размера сети.

Накопление ошибок и идея DAgger

Почему ошибки на записи недостаточно для оценки

В записи модель получает состояния, которые посетил эксперт. При собственном управлении даже небольшое отклонение действия меняет следующее состояние, затем модель встречает менее знакомые состояния и ошибается снова. Поэтому низкая ошибка на демонстрациях не гарантирует устойчивого управления в замкнутом контуре. Важно сравнивать не только команды, но и посещаемые состояния, число защитных вмешательств и завершение эпизода.

Задача 3. Проверка по записи и в замкнутом контуре

Сначала воспроизведи наблюдения тестовой выборки и вычисли ошибку действий без влияния модели на симуляцию. Затем в отдельной оценочной среде разреши ВС выбирать поправку верхнего уровня через защитный фильтр, сохраняя те же начальные условия. Сравни траектории корпуса, максимум наклона, время восстановления, частоту ограничения и отклонения команд (clamp и reject) и число падений. Параметры фильтра одинаковы для всех сравниваемых контроллеров.

Выбери один эпизод, где ошибка растёт постепенно. Найди первый момент заметного расхождения и сравни наблюдение с диапазоном обучающей выборки. Не объясняй всё одним словом «OOD»: проверь задержку, нормализацию, привилегированные признаки эксперта и реальную чувствительность динамики к действию. Сохрани график причинной цепочки «ошибка команды → изменение состояния → следующая ошибка».

Задача 4. Минимальная итерация DAgger

Разбери принцип: собирать состояния, посещаемые текущей политикой, запрашивать в них действие эксперта и добавлять пары в обучающий набор. Для учебного опыта достаточно одной ограниченной итерации в симуляции. Эксперт даёт метки в новых состояниях, а независимый фильтр контролирует исполнение. Не продолжай эпизод за пределами допустимого состояния только ради разнообразия данных.

Добавь новые эпизоды только в обучающую выборку; валидационную и итоговую тестовую выборки для обучения не используй. Переобучи модель тем же способом и сравни результаты на отдельном диагностическом наборе эпизодов управления. Покажи, как изменились распределение состояний, ошибки действий и число вмешательств. Если улучшения нет, зафиксируй это. Одна итерация не подтверждает все теоретические свойства DAgger; бесконечно накапливать данные здесь не требуется.

Перенос идеи на руку

Представь палец, который прижимает предмет: маленькая ошибка может сдвинуть объект, и следующие состояния перестанут совпадать с демонстрацией. Опиши доступные измерения, экспертную команду и условие прекращения контакта. Это упражнение выполняется письменно в рамках времени на анализ; не запускай второй проект обучения. Главная мысль для обоих роботов — качество замкнутого поведения оценивается отдельно от точности подражания на чужой траектории.

Зафиксируй ВС как самостоятельную версию. При переходе к РРО не стирай её результаты: подражание эксперту и улучшение управления с помощью корректирующей добавки решают разные задачи, и результаты обеих должны оставаться доступными для проверки.

MDP и среда с понятными действиями

Контракт задачи обучения

MDP описывается состоянием, действием, переходом, наградой и правилом завершения. Реальный агент получает наблюдение, которое может не содержать полного состояния; тогда для него возникает частичная наблюдаемость. Для малого опыта используй доступные крен и тангаж, угловые скорости, ошибки желаемой позы, контактные статусы, возраст измерений и предыдущее действие. Точный коэффициент трения или будущий толчок не входят в наблюдение.

Задача 5. Среда Gymnasium

Реализуй `reset(seed)` и `step(action)` вокруг существующего симулятора. Действие — два нормированных значения в диапазоне $[-1, 1]$, которые масштабируются в небольшую корректирующую добавку по крену и тангажу к классической команде. Максимальную поправку и скорость её изменения выводи из ранее проверенного диапазона симуляции. Политика не управляет токами напрямую. Регулятор нижнего уровня и монитор используют свои неизменённые ограничения.

Соблюдай порядок одного шага: проверь свежесть наблюдения, вычисли исходное действие, примени фильтр, выполни несколько шагов физики с отфильтрованной командой, получи новое наблюдение, награду и признак завершения. Сохраняй исходное (`raw`) и применённое (`applied`) действия отдельно. Если фильтр часто заменяет действие, результат определяется и политикой, и защитой; отрази это в метриках. Выход за численные пределы и падение завершают эпизод по условию задачи, а административный лимит времени обозначается `truncated`.

Задача 6. Награда и нежелательные стратегии

Начни с отрицательной взвешенной суммы квадратов ошибки ориентации корпуса, угловой скорости, величины корректирующей добавки и изменения действия. Нормируй величины на объявленные характерные масштабы, чтобы веса имели понятный смысл. Если награда аппроксимирует интегральный штраф, учитывай dt одинаково при смене частоты. Добавь штраф за нарушение условий, но не рассчитывай, что штраф заменит жёсткий защитный фильтр.

Вручную проверь четыре последовательности: удержание, дрожащая поправка, быстрое прекращение эпизода и пассивное ожидание. Рассчитай составляющие награды. Раннее падение не должно выглядеть выгодным только потому, что прекращает накопление отрицательных затрат. Сохраняй компоненты награды и отдельно признак успеха (`success`) по инженерным критериям. Увеличение возврата без уменьшения наклона или отказов не объявляется улучшением робота.

Проверь `reset`: одинаковый `seed` воспроизводит начальные условия, разные значения `seed` действительно меняют объявленные параметры, а состояние фильтра и предыдущая команда очищаются. Утечка состояния между эпизодами способна создать скрытую зависимость результатов от порядка испытаний.

РРО: небольшой воспроизводимый эксперимент

Что нужно понять об алгоритме

РРО обновляет политику по данным взаимодействия со средой, ограничивая изменения в целевой функции. Разбери траекторию, возврат, дисконтирование, функцию ценности, преимущество действия и отсечение отношения вероятностей. Используй Stable-Baselines3 и простой многослойный перцептрон (MLP). Все доказательства и собственная система RL не требуются; смысл наблюдения, действия и завершения эпизода нужно понимать до запуска.

Задача 7. Проверка среды и первый запуск

Сначала выполни автоматическую проверку API среды, испытания со случайными допустимыми действиями и с нулевой корректирующей добавкой. При нулевой добавке поведение должно совпадать с зафиксированным базовым алгоритмом при том же регуляторе нижнего уровня. Затем запусти очень короткое обучение для технической проверки: награда конечна, эпизоды завершаются корректно, веса монитора не меняются, счётчик шагов растёт. Исправь ошибки среды до настройки РРО.

Зафиксируй число шагов сбора данных, размер пакета, скорость обучения, коэффициент дисконтирования и общую границу шагов. Возьми начальную конфигурацию документации, адаптируя только необходимое к частоте и длине твоего эпизода; все изменения объясни. Не запускай десятки вариантов, выбирая лучший на тестовых воздействиях. Один выбранный РРО-эксперимент соответствует договорённому масштабу месяца.

Задача 8. Три запуска и воспроизводимые кривые

Выполни три независимых запуска с заранее перечисленными значениями seed, одинаковыми лимитами и отдельными каталогами. Не считай три оценки одной обученной сети тремя независимыми запусками обучения. У каждого сохраняй кривые обучения, контрольные точки и журнал времени. Для модели, остановленной по истечении времени, укажи фактическое число взаимодействий: более быстрый запуск мог увидеть больше данных. Для строгого сравнения по шагам используй общую достижимую границу.

После обучения оцени все три политики на одинаковом списке независимых эпизодов. Приведи результаты каждой и агрегированное среднее с разбросом, а также результат при самом неудачном значении seed. Не выбирай для итогового графика только удачный экземпляр. Контрольную точку выбирай по валидационной выборке; итоговую тестовую используй после того, как выбор зафиксирован. Если все модели хуже базового алгоритма, это полноценный отрицательный результат ограниченного эксперимента.

Когда остановить обучение

Лимит — 50 000 шагов либо 30 минут на значение seed; при медленной физике он уменьшается одинаково. Этот бюджет может быть недостаточен для улучшения — так и укажи. Нельзя компенсировать нехватку времени отключением монитора или подачей эталонного состояния в наблюдения без объявления другой постановки. Сначала проверь качество среды, масштаб действий и награду, затем в будущем выделяй новый вычислительный бюджет.

Обязательная ветка выполняется на CPU. Решение об ускорителе принимай после измерения затрат времени: вычисления малого MLP могут занимать меньше времени, чем расчёт физики. Isaac Lab и массовые среды на GPU — отдельный выбор, который не является условием завершения M21.

Рандомизация параметров с физическим смыслом

Пять семейств неопределённости

Масса и инерция меняют требуемые силы; трение влияет на допустимость контакта; задержка меняет момент применения команды; шум и смещение датчика искажают наблюдение; высота и наклон рельефа меняют опору. Не задавай произвольные диапазоны без обоснования устойчивости. Для каждого семейства запиши номинальное значение, диапазоны обучения и валидации, а также отдельный диапазон OOD, единицы и источник: измерение, спецификация либо условный диапазон учебной симуляции.

Задача 9. Реестр рандомизации

Случайно выбирай массу и трение при сбросе среды, а шум — по явно заданной модели во времени; задержка может быть постоянной внутри эпизода либо меняться по объявленному правилу. Сохраняй фактические выбранные параметры каждого эпизода. Не изменяй массу без согласования инерции и не создавай отрицательное трение или невозможную геометрию. Если физическая достоверность нарушена, пример помечается как некорректная симуляция и не учитывается как корректный тест OOD.

Начни с узкого диапазона, который проходит классический базовый алгоритм. Постепенно усложняй обучение при выполнении заранее заданного критерия, например достаточной доли эпизодов без падения и чрезмерных вмешательств на валидационной выборке. Порог выбирается для учебного сценария до запуска. Переход не зависит от итоговой тестовой выборки, а время на этапах и границы сохраняются в конфигурации.

Задача 10. Абляции семейств

Для основного результата обучения РРО с выбранным набором рандомизаций. Затем выполни пять коротких предварительных вариантов: по очереди отключи рандомизацию массы, трения, задержки, шума и рельефа, оставляя остальные условия и один заранее выбранный seed неизменными. Бюджет — до 10 минут на вариант. Оцени их на одинаковом диагностическом наборе по соответствующему семейству. Это ограниченная абляция обучения; по одному значению seed нельзя вывести устойчивый причинный эффект.

Отдельно оцени уже обученную модель при последовательном изменении параметров: меняй только одно семейство, оставляя остальные в номинальном состоянии. Построй зависимости отказов и ошибок от величины изменения. Эти два опыта отвечают на разные вопросы: нужна ли рандомизация при обучении и как готовая политика реагирует на сдвиг условий. Простое варьирование параметров при оценке не доказывает эффект рандомизации при обучении.

Границы переноса из симуляции на оборудование

Рандомизация расширяет знакомые условия, но не гарантирует, что модель охватит все условия реального оборудования. Люфт, упругость, нагрев, задержки связи и ошибки контакта могут отсутствовать в модели. Составь список таких расхождений и способ их измерить позже. На руке добавились бы трение предмета, податливость пальца и свойства тактильного датчика; текущая политика корпуса не переносится туда заменой названий переменных.

Независимый монитор, OOD и резервное управление

Раздели оценку политики и право исполнить команду

Защитный фильтр политики (policy shield) — блок, который проверяет либо ограничивает предложенную поправку по известным условиям. Он не обучается вместе с PPO и не получает награду за пропуск опасной команды. Проверяются конечность, амплитуда, скорость изменения, возраст наблюдений, поза, контакты и доступные пределы исполнительной цепочки. QP и контроллер M20 сохраняет свои ограничения полной команды, в том числе момента и моделируемого тока.

Задача 11. OOD-индикатор и пределы его надёжности

Начни с простого контроля диапазонов стандартизованных признаков и расстояния до обучающих данных. Пороги выбери по валидационной выборке, затем зафиксируй. Зафиксируй, что такой индикатор пропускает некоторые незнакомые состояния и может отвергать знакомые. Вероятность действия, энтропия политики PPO или уверенность сети не являются гарантией физической надёжности. Для каждого OOD-сценария измеряй ложные срабатывания и невыявленные плохие эпизоды.

Внеси тестовые нарушения: смещение датчика, запоздавшее наблюдение, новый уклон, низкое трение и отсутствие стопы. Запиши моменты первого недостоверного входа, срабатывания монитора и перехода в резервный режим. Рассчитай задержку реакции по одной временной шкале. Проверь также новую комбинацию условий, каждое из которых лежит в допустимом численном диапазоне: покомпонентная проверка может её не распознать.

Задача 12. Переход к резервному управлению

При отклонении команды (reject) обучаемая корректирующая добавка отключается по заранее заданному правилу; классическое стояние (stand) или пауза походки (gait pause) остаются доступными. При обычном отключении поправку можно плавно уменьшать в допустимых пределах. При нарушении критического ограничения защита имеет приоритет над плавностью. Нельзя продолжать применять устаревшее действие обученной политики «ещё несколько отсчётов», если срок его пригодности истёк.

В режиме ВС возврат восстанавливает экспертную команду верхнего уровня, а при PPO с корректирующей добавкой — обнуляет добавку к базовому управлению. Регулятор нижнего уровня в обоих случаях одинаков. Для возобновления ML нужны достоверные данные в течение заданного времени и явное условие автомата; одного нормального отсчёта недостаточно. Записывай долю времени под базовым управлением: если защита почти постоянно заменяет политику, нельзя приписывать ей все успешные эпизоды.

Выполни принудительный переход в резервный режим во время отклонения корпуса и сравни с отключением в спокойной стойке. Покажи исходное и применённое действия, состояние, причину и ограничения. Возможность возврата не доказывает, что любое уже опасное состояние спасемо; за пределами проверенной области фиксируется отказ, а не гарантированное восстановление.

Интегрированная оценка learning_eval_v1

Режимы сравнения

Сравни четыре явно обозначенных режима: классическое базовое управление; клонирование верхней команды; базовое управление с корректирующей добавкой PPO; тот же PPO с обязательным монитором и резервным режимом. Если для диагностики нужен незащищённый PPO, запускай его только в симуляции с внешними условиями остановки; такой опыт не даёт допуска к оборудованию. BC и PPO с добавкой решают разные задачи, поэтому ошибка предсказания действия не служит общей оценкой качества управления.

Основной кандидат для дальнейшего применения — защищённая схема. Для сопоставимого сравнения базовый алгоритм использует те же датчики, задержки, ограничения и сценарии. Начальные состояния, воздействия и значения seed при оценке общие; значения seed при обучении перечисляются отдельно. Если после неудачи ML базовый алгоритм изменён, повтори весь набор сравнений и явно укажи его новую версию.

Задача 13. Сравнение восстановления после толчка

Задай малый воспроизводимый импульс в известной точке корпуса и времени эпизода, в пределах ранее проверенной симуляции. Изменяй направление и интенсивность по фиксированной сетке. Для каждого режима измерь максимум наклона, время возвращения в объявленный коридор с выдержкой, RMS ошибки, насыщения, ограничения и отклонения команд, падения и успешное завершение. Сохрани также эпизоды без толчка: политика не должна ухудшать обычную стойку ради редкого успешного восстановления.

Награда выводится отдельной колонкой. Если награда растёт, а число вмешательств или падений увеличивается, это повод пересмотреть цель, а не объявить успех. Укажи число эпизодов для каждой клетки и покажи все три запуска PPO с разными значениями seed. Простой разброс по значениям seed не заменяет статистику по разнообразным сценариям; покажи оба источника неопределённости.

Задача 14. Протокол переноса на оборудование без запуска приводов

Подготовь последовательность будущих проверок: сверка единиц и схемы; обработка реальных записей без управления; модель в теневом режиме без воздействия на робота; ограниченный стенд с известными нагрузками; проверка независимых ограничений и остановки; только затем рассмотрение физического применения. Для каждого шага укажи необходимые данные и критерий перехода. В M21 оформляется протокол, а не выполняется автоматическое развёртывание.

Допустимые ток, температура и момент, а также механические границы определяются по конкретным приводам и испытаниям предыдущих этапов. Если их нет, это незакрытая зависимость. Отдельный G3 включает аудит данных, модели и применения, а также решение по Jetson и обучаемому управлению движением; перенос его даты не разрешает обойти проверки. CPU-путь M21 не зависит от покупки ускорителя. Для M22 передавай работающий классический алгоритм независимо от того, оказалось ли обучение полезным.

Пошаговый график занятий: 1-75

Блок 1: часы 1-20

1-2: проверка базового алгоритма и доступных наблюдений. 3-4: обучение по демонстрациям и функция потерь для действий. 5-6: разделение данных по группам и разметка демонстраций. 7-8: накопление ошибок и сдвиг распределения состояний. 9-10: идея DAgger и протокол эпизода управления. Практика 11-20: по 2 часа на сбор и аудит данных, разделение выборок и нормализацию, обучение ВС, оценку в замкнутом контуре и одну ограниченную итерацию добавления данных. Сохрани результаты до перехода к RL.

Блок 2: часы 21-40

21-22: MDP и частичная наблюдаемость. 23-24: наблюдение, действие и частота политики. 25-26: награда, завершение по условию задачи и обрыв по внешнему ограничению. 27-28: возврат, преимущество действия и отсечение в PPO. 29-30: значения seed, выбор контрольной точки и независимая оценка. Практика 31-40: 2 часа на среду и сброс; 2 на награду и нулевую добавку; 2 на короткую проверку PPO и настройку журналов; 2 на три ограниченных запуска с параллельным анализом журналов; 2 на сравнение и архивирование.

Блок 3: часы 41-60

41-42: физический смысл массы, инерции и трения. 43-44: задержки, шум и временная корреляция. 45-46: рельеф, диапазоны обучения и OOD. 47-48: постепенное усложнение обучения и допуски. 49-50: различие абляции обучения и варьирования параметров при оценке. Практика 51-60: 2 часа на реестр параметров; 2 на основную конфигурацию с рандомизацией; 2 на ограниченные абляции; 2 на варьирование параметров по семействам; 2 на разбор неудач. При переобучении основного варианта с рандомизацией сохрани три значения seed и тот же лимит на запуск; это входит в данный блок.

Блок 4: часы 61-75

61-62: OOD-индикаторы и пределы их надёжности. 63-64: независимый защитный фильтр, ограничения полной команды и резервный режим. Час 65: письменный протокол переноса на оборудование и критерии решения. Практика 66-75: 2 часа на монитор и внесение ошибок во входные данные; 2 на переходы в резервный режим; 2 на общий тест с толчком; 2 на оценку всех моделей и значений seed; 2 на повторение из чистого каталога и итоговый отчёт.

Что сохранять после каждого занятия

Теоретическое занятие заканчивается схемой, ручным примером или решением о требованиях к интерфейсу. Практическое — конфигурацией, сырым логом, численным показателем, неудачным случаем и следующим вопросом. Обучение без новых проверок не продлевай: учебная цель — понять, почему политика работает или не работает в установленном бюджете. Время очереди, загрузки и ожидания не должно поглотить анализ датчиков, ограничений и качества сравнения.

Приёмка: восемь проверок и итоговое решение

Обязательные сценарии

1. Нулевая корректирующая добавка. Поведение полностью совпадает с базовым алгоритмом; различие указывает на ошибку программной обёртки. **2. Ошибочный reset.** Повтори значение seed и проверь очистку предыдущих действий, фильтров и таймеров. Тест должен выявлять скрытую память между эпизодами.

3. Некорректное наблюдение. Поддай NaN, неверную схему и просроченные данные. Монитор отклоняет действие и записывает причину. **4. Действие на пределе.** Поддай большой скачок выхода политики. Проверь амплитуду, скорость изменения и полную команду после регулятора нижнего уровня; каждое ограничение команды отрази в отчёте.

5. OOD-трение или масса. Измени одно семейство за пределы диапазона обучения, сохраняя физическую корректность. Измерь ошибки, падения и обнаружение OOD; высокая уверенность сети не исключает отказ. **6. Комбинация знакомых крайностей.** Совмести задержку, шум и уклон внутри отдельных диапазонов. Покажи, может ли простой детектор пропустить опасное сочетание.

7. Принудительный резервный режим. Отключи политику в спокойной и отклонённой стойке. Измерь скачок команды и восстановление, проверь отсутствие самопроизвольного повторного включения. **8. Одинаковый толчок.** Прогони общий список эпизодов для базового алгоритма, ВС и трёх запусков PPO с разными значениями seed. Сохрани плохие результаты и сравни инженерные метрики с наградой.

Критерии завершения

Подготовлены неизменная версия базового алгоритма, описание демонстраций, разделение выборок без утечки, модель ВС, проверенная среда и ограниченные запуски PPO минимум с тремя значениями seed либо документированная причина остановки до обучения.

Сохранены конфигурации, нормализация, контрольные точки, фактические шаги и время, профили OOD, абляции и отчёт о резервном режиме. Если проверки базового алгоритма или монитора не пройдены, применение обученной политики не допускается; явно отметить это в результате.

Итоговое решение содержит один из вариантов: оставить базовый алгоритм; продолжить исследование в симуляции; подготовить отдельный следующий этап проверки. Не выбирай физический запуск по этой таблице автоматически. Улучшение объявляется только относительно заранее выбранных показателей без ухудшения обязательных ограничений. Для политики с частыми вмешательствами отдельно укажи, какую часть успеха обеспечивает классический контур.

Самопроверка и сокращение

Объясни различия оценки по записи и в замкнутом контуре, ВС и корректирующей добавки, состояния и наблюдения, terminated и truncated, награды и успеха, рандомизации при обучении и сдвига условий при оценке. Покажи скрытую информацию эксперта, выбор значений seed, работу защитного фильтра и пределы OOD-детектора. При нехватке времени исключи Isaac Lab, новые архитектуры и расширенное усложнение обучения. Сохрани малую среду на CPU, независимые запуски, классическое сравнение, OOD и резервный режим. Отсутствие выигрыша допустимо; без проверок работа не завершена.

Литература: подражание и один RL-эксперимент

Литература может быть на английском; задания и определения здесь на русском. Читай только названные разделы перед соответствующей работой, в пределах прежних 75 часов.

Основное чтение: три источника

1. R. Sutton, A. Barto - Reinforcement Learning: An Introduction, 2-е изд. Оглавление издателя. Разделы 3.1–3.5: взаимодействие, награда, эпизод, политика и ценность; 13.1, 13.3–13.5: градиент политики, REINFORCE и actor-critic. Для задач 5–8 выпиши MDP своей среды и смысл преимущества действия; всю книгу читать не требуется.

2. S. Levine - CS 185/285, Supervised Learning of Behaviors. Лекция 2, части 2, 3 и 5: алгоритм BC, распределительный сдвиг и DAgger. Перед задачами 1–4 объясни, почему ошибка на записанных кадрах отличается от ошибки при собственном управлении в замкнутом контуре.

3. R. Tedrake - Underactuated Robotics, конспект MIT. Model-Free Policy Search → Policy Gradient Methods. Выборочно REINFORCE и Sample efficiency. Перед тремя запусками с разными значениями seed оцени стоимость одного опыта и объясни, почему малый CPU-бюджет ограничивает выводы, а не доказывает неудачу RL.

Справочные разделы для практических задач

Stable-Baselines3. PPO: Notes, Example, Parameters и RL Tips: Evaluation, Custom environments. Для задач 7–8: одна закреплённая реализация, одинаковые сценарии сравнения и несколько значений seed.

Gymnasium. Env: reset, step, spaces и Handling Time Limits. Для задачи 5: контракт среды, различие terminal и truncated и корректная оценка будущего возврата.

Необязательно: оригинальные статьи

Ross и соавт.: DAgger, алгоритм агрегации; Schulman и соавт.: PPO, clipped objective; Tobin и соавт.: Domain Randomization. Последняя работа преимущественно о визуальном переносе; диапазоны массы, трения и задержки требуют отдельного обоснования.

Результат чтения: одна страница с MDP, различием BC и корректирующей добавки PPO и критериями возврата к замороженному контроллеру.

Понятия и определения

Клонирование поведения (BC). Обучение отображения наблюдения в действие по размеченным примерам эксперта с обычной функцией ошибки предсказания.

DAgger. Итеративное добавление в обучающий набор состояний текущей политики с действиями, заново размеченными экспертом в этих состояниях.

MDP. Модель последовательных решений: состояние, действие, вероятностный переход и награда; следующее состояние зависит от текущего состояния и действия.

Наблюдение (observation). Информация, доступная агенту на шаге; может не содержать части физического состояния, из-за чего вход не обладает марковским свойством.

Политика (policy). Правило выбора действия по доступной информации; стохастическая политика задаёт распределение вероятностей допустимых действий.

Награда (reward). Число, получаемое за один переход; выражает выбранную цель обучения, но само по себе не является инженерным критерием успеха.

Возврат (return). Сумма будущих наград с заданным дисконтированием от выбранного момента эпизода; случайная величина до наблюдения траектории.

Дисконт γ . Безразмерный множитель будущих наград; γ ближе к единице увеличивает относительный вклад более отдалённых последствий.

Ценность состояния V . Ожидаемый возврат при начале в данном состоянии и последующем выполнении указанной политики в заданной среде.

Преимущество (advantage). Разность ожидаемой ценности конкретного действия $Q(s,a)$ и средней ценности состояния $V(s)$; измеряет относительную полезность действия.

PPO. Алгоритм обновления политики с отсечением отношения вероятностей во вспомогательной целевой функции; это смягчает изменения, но не гарантирует безопасность движения.

Корректирующая политика (residual policy). Ограниченная обучаемая добавка к команде регулятора; её масштаб, скорость изменения и отключение задаются отдельно.

Эпизод управления (rollout). Последовательность взаимодействий политики со средой: наблюдения, действия, награды и завершения; отличается от воспроизведения фиксированной записи.

Завершение и обрыв (termination и truncation). Окончание по условию задачи и прерывание по внешнему лимиту по-разному влияют на оценку будущего возврата.

Сдвиг распределения. Изменение частот или области наблюдаемых состояний относительно обучающей выборки, включая последствия собственных ошибочных действий агента.

Рандомизация среды (domain randomization). Выбор параметров симуляции из заданных распределений при обучении; диапазоны соответствуют физическим допущениям опыта.

OOD. Условия вне установленного распределения обучения; детектор может пропустить их, поэтому независимые ограничения сохраняют силу.

Резервный режим (fallback). Проверенный переход к классическому режиму или остановке при отказе обученной части; требует собственного условия и теста переключения.

Связи: $G_t = r_{t+1} + \gamma G_{t+1}$; $A(s,a) = Q(s,a) - V(s)$. Проверка: высокая награда и малая функция потерь BC ещё не подтверждают устойчивое поведение.

Что использовать, покупать и устанавливать

ИСПОЛЬЗОВАТЬ ИМЕЮЩЕЕСЯ

Используй MacBook Pro M4, среду M18 для CPU, модель и симулятор M19–M20, неизменный классический базовый алгоритм и журнал экспериментов. Физические приводы в обучающих эпизодах не участвуют; MCU, IMU и камера остаются для прежних задач.

ПОКУПКИ СЕЙЧАС

Новых обязательных покупок нет. Не заказывай Jetson, видеокарту или дополнительные приводы для выполнения M21. Три коротких запуска PPO с разными значениями seed и обучение BC укладываются в установленный учебный лимит; достижение заданной награды не обещается.

УСТАНОВИТЬ СЕЙЧАС

В отдельное окружение M21 добавь **stable-baselines3** и **gymnasium**; используй совместимую закреплённую версию PyTorch CPU из M18. Официальная установка SB3: Prerequisites, Stable Release. Сохрани lock-файл; дополнительные пакеты Atari и Box2D для этой задачи не нужны.

Система: обучай модель вместе с действующим симулятором в Ubuntu 24.04 ARM64 под UTM; анализ BC можно выполнять непосредственно на macOS ARM. При работе в разных системах фиксируй версии, архитектуру и формат данных. Результаты не объявляются побитово одинаковыми между платформами: PyTorch: Reproducibility.

ПРОВЕРКА УСТАНОВКИ

Импортируй torch, gymnasium, stable_baselines3; убедись, что модель работает на CPU. Выполни check_env, reset с фиксированным seed, 100 допустимых шагов и короткое обновление PPO. Проверь конечность чисел, отдельные признаки terminated и truncated, сохранение и загрузку политики; затем убедись, что при нулевой корректирующей добавке поведение совпадает с базовым алгоритмом.

ОПЦИОНАЛЬНО, ПОСЛЕ УСЛОВИЯ

Второй симулятор не требуется: ранее установленный MuJoCo используй только для уже выбранного сравнения. оборудование NVIDIA и Isaac Lab рассматривай после измеренного дефицита CPU и отдельного решения G3, который запланирован на 27.11–10.12.2028. Isaac Lab: требования и установка. Apple M4 не поддерживает CUDA; этот путь не является предпосылкой M21.

Подготовка и проверки входят в существующие 75 часов вместо повторного чтения и настройки. Ожидание доставки учебными часами не считается.

Основы движения: физический смысл действия модели

Обязательный разбор: действие, реальное воздействие и шаг времени

До обучения объясни путь: наблюдение → поправка цели → регулятор нижнего уровня → привод → механическое движение → датчик. Нормированное действие сети не имеет единиц момента. В M21 оно задаёт поправку крена и тангажа; силовое воздействие вычисляет существующий контроллер. Одна и та же поправка может вызвать разные моменты при разной нагрузке.

Минимальная модель: от причины к изменению состояния

Для отдельного шарнира q — угол в рад, ω — скорость в рад/с. Модель $I \cdot d\omega/dt = \tau_{\text{net}}$ связывает момент инерции I в кг·м² и суммарный момент τ_{net} в Н·м; в него уже включены привод, тяжесть и трение со знаками. Если держать I и τ_{net} постоянными на малом интервале Δt , то $\Delta\omega = \tau_{\text{net}} \cdot \Delta t / I$. Положение и скорость нужны вместе: одинаковый q не определяет следующее состояние.

Пример. $I = 0.02$ кг·м², $\tau_{\text{net}} = 0.10$ Н·м, $\Delta t = 0.02$ с, начальная $\omega = 0$: ускорение 5 рад/с², конечная $\omega = 0.10$ рад/с, изменение угла 0.001 рад. Удвой I при том же моменте: скорость станет 0.05 рад/с. Это аналитический тест физики; он не меняет интерфейс политики на управление моментом.

Практика: выявить ошибки единиц и частоты

1. Проследи действие. В отдельном тесте нормированное $a = 0.5$ при учебном масштабе 0.04 рад означает целевую поправку 0.02 рад. Сохрани исходное действие, цель, применённую команду и наблюдение. Для реальной среды используй её уже проверенный предел. При нулевой корректирующей добавке проверь совпадение с базовым алгоритмом; при насыщении выясни, какой уровень управления изменил запрос.

2. Проверь интегральный штраф. Для постоянной ошибки $e = 0.1$ рад и масштаба $e_0 = 0.1$ рад интегральный штраф за ошибку за 1 с равен сумме $(e/e_0)^2 \cdot \Delta t = 1$ с. При $\Delta t = 0.02$ и 0.01 с ответ одинаков; сумма без Δt станет 50 и 100. Повтори на сохранённой траектории, чтобы отделить ошибку метрики от влияния частоты управления на само движение.

Приёмка и место в расписании

Сохрани `action_physics.md`, таблицу единиц и тесты. Объясни, почему удвоение массы не всегда удваивает все компоненты инерции и почему задержка меняет замкнутую динамику. Выдели 1 ч из разбора 23–26 и 2 ч из практики 31–34 на определение действия и награды. Это уточняет задачи 5–6 внутри прежних 75 ч; нового обучения или оборудования не требуется.

Что прочитать: Russ Tedrake, [Underactuated Robotics, Definitions](#) - состояние и уравнения механической системы; Lynch, Park, [Modern Robotics §8.9](#) - передача и физический смысл привода.